

Propuesta pipeline MLOps end-to-end v2.0

Proyecto: Estado clínico simulado (2MLops). **Producción objetivo:** LightGBM + MLflow. **MVP implementado:** reglas en modelo_simulado.py. **Despliegue:** local (Docker Compose) y cloud (Cloud Run). Alcance académico; no uso clínico real.

Resumen del problema

Un médico ingresa al menos tres signos (presión, colesterol, glucosa, etc.) y obtiene una de cuatro etiquetas. El pipeline MLOps garantiza datos versionados, entrenamiento trazable, empaquetado reproducible, inferencia local o remota, monitoreo y reentrenamiento continuo.

Registro de suposiciones (extracto)

- S1: CSV ~70k filas representa dominio académico.
- S3: Inferencia CPU <100 ms; modelo <10 MB.
- S6: Clase AGUDA ~1,9 % — requiere estratificación y recall como gate.
- S8: Médico usa Docker local o HTTPS cloud con API key.

Diagrama 1 — Pipeline 12 etapas





Diagrama 2 — Despliegue híbrido



El médico puede ejecutar la solución en su PC (Docker Compose, localhost:5000) o consumir la misma API vía HTTPS en Cloud Run con API key. Misma imagen GHCR y mismo contrato JSON POST /predecir.

Diagrama 3 — CI/CD





Diagrama 4 — Datos → ML → serve

Flujo datos → ML → inferencia



Etapas del pipeline (síntesis)

0 Encuadre. Alcance, KPIs, disclaimer. Markdown + RACI.

1 Ingesta. Git + DVC + MinIO/S3. Snapshot data@vN.

2 Catálogo. Linaje DVC; OpenMetadata opcional.

3 Calidad. Great Expectations; gate en CI.

4 Features. pandas + sklearn Pipeline + Feast offline.

5 Entrenamiento. LightGBM + Optuna + MLflow Tracking.

6 Evaluación. SHAP + gate humano; beat baseline reglas.

7 Registry. MLflow Staging → Production; rollback.

8 Empaquetado. Docker multi-stage → GHCR.

9 Local. Docker Compose perfil local; sin GPU.

10 Cloud. Cloud Run / App Runner; TLS + API key.

11 Monitoreo. Prometheus, Grafana, Evidently drift.

12 Retrain. GitHub Actions / Prefect; triggers drift/F1/cron.

Enfermedades huérfanas y desbalance

AGUDA es ~1,9 % del dataset: estratificación, class_weight en LightGBM, recall AGUDA como criterio de promoción, monitoreo de frecuencia en producción. Patologías raras no presentes en CSV: no se diagnostican por nombre; flag requiere_revision_humana propuesto; datos nuevos en cuarentena.

Baseline vs producción

MVP (implementado): reglas deterministas + Flask + Docker. Producción (objetivo): LightGBM registrado en MLflow. Promoción solo si F1 macro y recall AGUDA superan baseline en mismo test split.

Plan de puesta en marcha (equipo ML)

Fase 0 (1 sem): baseline operativo — hecho. Fase 1 (1–2 sem): DVC + GX + catálogo. Fase 2 (2 sem): LightGBM en MLflow + SHAP. Fase 3 (1 sem): GHCR + local + Cloud Run. Fase 4 (1 sem): Grafana + Evidently + workflow retrain. Total ~6–7 semanas, 2–3 personas.

Viabilidad

Stack open source y free tiers. Datos y MVP ya en repo. Cada etapa tiene suposiciones, tecnologías justificadas, criterios de aceptación y relación con código actual. Ver CHANGELOG.md para cambios vs Semana 1.

Documento académico v2.0 — no constituye asesoría clínica.