

Explicación por etapas.

- (1) Datos brutos: archivos CSV en *data/raw* y versiones procesadas en *data/processed*.
- (2) Ingesta y versionado: registro de conjuntos
- (3) Calidad y validación: comprobación de rangos y valores faltantes.
- (4) Preparación: limpieza, codificación de variables categóricas y partición entrenamiento/validación si hubiera modelo entrenado.
- (5) Entrenamiento y registro: es la fase en la que el algoritmo de Machine Learning aprende a partir de los datos que ya fueron preparados y registro del modelo
- (6) Empaquetado: imagen Docker y dependencias fijadas.
- (7) Despliegue: ejecución del contenedor y exposición del endpoint */predecir*.
- (8) Monitoreo y retrabajo: métricas operativas y posible reentrenamiento o recalibración con datos nuevos.

Diseño

datos estructurados, lógica de predicción acotada, servicio HTTP y empaquetado con Docker para que otro evaluador pueda construir y ejecutar la imagen.

Restricciones.

Alcance académico (no es un producto clínico); recursos limitados (máquina local o contenedor único); dependencia de la calidad y licencia de los datos de ejemplo; tiempo de curso que impide montar orquestación compleja.

Limitaciones.

Las reglas de la función simulada no sustituyen criterio médico; no hay garantía de representatividad poblacional; riesgo de sesgo en los datos históricos; sin despliegue multi-región ni alta disponibilidad en la versión mínima del proyecto.

Tipo de datos.

Datos tabulares en CSV: variables demográficas y de riesgo (edad, género, medidas antropométricas, presión arterial, colesterol, glucosa, hábitos, etiqueta binaria de enfermedad en el dataset original).

Desarrollo

Tipo de modelo ML

En la consigna actual se prioriza una función determinista que imita una predicción con cuatro estados de salida. Eso equivale a un *baseline* de un un modelo supervisado clásico regresión logística. Con trazabilidad del experimento y del conjunto de entrenamiento.

Validación y pruebas.

Pruebas unitarias de la función de clasificación con casos límite (umbrales de presión, combinaciones de glucosa y colesterol); pruebas de contrato del API (JSON de entrada y salida, códigos HTTP); prueba manual del formulario web; validación del build de Docker. Si existiera modelo entrenado: partición entrenamiento/validación/prueba y métricas.

Despliegue, monitoreo y datos futuros

Despliegue de la solución.

Construcción de imagen Docker desde el Dockerfile del servicio, publicación en registro interno o entrega como artefacto de tarea, y ejecución con mapeo de puertos (por ejemplo 5000) para acceder a <http://localhost:5000/predecir>. En un entorno de clase, el despliegue suele ser local o en una VM compartida.

Nuevos datos y reentrenamiento.

Sí: con el tiempo suelen aparecer nuevos registros, cambios en la definición de variables o en la población atendida. Eso puede exigir reentrenar un modelo supervisado o recalibrar reglas y umbrales. El pipeline debería incluir triggers (por volumen de datos nuevos, degradación de métricas o calendario) y un proceso de aprobación antes de promover un modelo nuevo a producción.

